

Quantum Topological Graph Neural Networks per il Rilevamento di Anomalie Finanziarie Analisi, Implementazione e Valutazione su Dispositivi NISQ

Martino Papa

Università degli Studi di Firenze

1 febbraio 2026

Introduzione

Rilevamento di frodi finanziarie

Le frodi finanziarie moderne sono difficili da identificare, caratterizzate da:

- **Transazioni complesse:** Schemi di riciclaggio che coinvolgono decine di conti.
- **Pattern nascosti:** Anomalie topologiche invisibili alle analisi statistiche standard.

Lo standard attuale è rappresentato dalle **Graph Neural Network (GNN)**, modelli di deep learning geometrico capaci di elaborare dati strutturati a grafo.

Modellazione dei Dati

Transaction Graph

Definiamo il grafo delle transazioni finanziarie come $G = (V, E)$ con $|V| = N$, dove:

- **Nodi** ($v \in V$): Rappresentano i conti bancari.
- **Archi pesati** ($(u, v) \in E$): Rappresentano il flusso di denaro aggregato:

$$w_{uv} \doteq \sum_{t \in T_{uv}} \text{amount}(t)$$

- Ogni nodo possiede uno stato interno (α_i) normalizzato sul grado totale del grafo.

Limiti dello Stato dell'Arte (GNN)

Nonostante l'efficacia, le GNN classiche presentano criticità strutturali:

- ① **Visione Locale:** Tendenza ad uniformare le feature dei nodi distanti, perdendo informazioni su cicli o pattern a lungo raggio.
- ② **Black-box:** La natura delle reti neurali contrasta con le normative finanziarie (GDPR/AI Act) che richiedono spiegabilità.
- ③ **Onerosità:** L'addestramento richiede enormi moli di dati etichettati e risorse computazionali elevate.

La Proposta: Architettura QTGNN

Si propone l'utilizzo di una **Quantum Topological Graph Neural Network (QTGNN)**, un'architettura ibrida che integra:

- **GNN**: Per la modellazione delle relazioni locali.
- **TDA (Topological Data Analysis)**: Per l'estrazione di invarianti globali robusti (Numeri di Betti) che garantiscono stabilità al rumore.
- **QML (Quantum Machine Learning)**: Per un embedding efficiente e per catturare correlazioni non lineari tramite entanglement.

Modellazione Quantistica del Grafo

Generalized Amplitude Encoding (GAES)

Per codificare la struttura del grafo $G = (V, E)$ in uno stato quantistico, si adotta una variante dell'*Amplitude Encoding* arricchita da *Entanglement Seeding*. Lo stato target $|\psi_G\rangle$ è mappa la matrice di adiacenza, ed è definito:

$$|\psi_G\rangle = \frac{1}{\sqrt{Z}} \sum_{i,j} A_{ij} \mathcal{E}_{ij}(\theta_e) |i\rangle |j\rangle$$

L'obiettivo è mappare le relazioni pesate del grafo direttamente nell'entanglement tra qubit.

Entanglement Seeding (\mathcal{E}_{ij})

L'informazione sugli archi è codificata tramite l'operatore di entanglement \mathcal{E}_{ij} , che agisce tra i qubit del registro sorgente e quelli di ambiente.

$$\mathcal{E}_{ij}(\theta_e) \doteq \exp(-i\theta_e \sigma_i^x \sigma_j^x)$$

Dove:

- θ_e : Parametro addestrabile che modula l'intensità dell'interazione.
- σ^x : X-Gate che creano correlazioni non classiche.

Matrice di Interazione A_{ij}

Il tensore A_{ij} unifica le informazioni topologiche e le feature dei nodi.

$$A_{ij} \doteq \begin{cases} w_{ij} & \text{se } i \neq j \quad (\text{Peso cumulativo transazioni}) \\ \alpha_i & \text{se } i = j \quad (\text{Centralità di grado normalizzata}) \end{cases}$$

Dove $\alpha_i = \frac{\deg(i)}{\sum_k \deg(k)}$. Questo permette di processare simultaneamente flussi e importanza dei nodi.

Matrice Densità Ridotta

Dallo stato puro $|\psi_G\rangle$, ricaviamo la matrice di densità ridotta ρ_G :

$$\rho_{total} = |\psi_G\rangle \langle \psi_G|$$

$$\rho_G = Tr_{env}(\rho_{total}) \doteq \sum_{m \in env} (\mathbb{I} \otimes \langle m |) \rho_{total} (\mathbb{I} \otimes |m \rangle)$$

ρ_G incapsula le proprietà topologiche del grafo in uno stato misto di dimensione ridotta (n qubit).

Variational Quantum Graph Convolution

Evoluzione variazionale del grafo

Si utilizzano circuiti quantistici parametrizzati per evolvere lo stato ρ_G attraverso L layer di convoluzione quantistica variazionale (VQGC).

Definizione ricorsiva

$$\rho^{(0)} = \rho_G$$

$$\rho^{(l+1)} = \mathcal{N}_\theta^{(l)} \left(U_\theta^{(l)} \rho^{(l)} U_\theta^{(l)\dagger} \right)$$

Definizione dell'operatore unitario

Operatore di Evoluzione Unitaria

$$U_{\theta}^{(l)} = \exp \left(-i \sum_{(i,j) \in E} \theta_{ij}^{(l)} H_{ij} - i \sum_{i \in V} \phi_i^{(l)} \sigma_i^z - i \sum_{(i,j,k) \in \Delta} \psi_{ijk}^{(l)} \sigma_i^z \sigma_j^z \sigma_k^z \right)$$

- $\theta_{ij}^{(l)}$: Dinamica sulle connessioni dirette (Archi).
- $\phi_i^{(l)}$: Dinamica specifica del conto (Nodi).
- $\psi_{ijk}^{(l)}$: Interazioni multi-partito su strutture triangolari

Phase Damping

Per introdurre non-linearietà, si applica inoltre un canale di dephasing:

Dephasing mediante operatori di Kraus

$$\mathcal{N}_\theta^{(l)}(\rho) = \sum_k p_k(\theta) \Pi_k \rho \Pi_k$$

Con operatori di Kraus: $\Pi_0 = I = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \quad \Pi_1 = \sigma^z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$

E probabilità associate: $p_0(\theta) = \frac{e^{\theta_0}}{e^{\theta_0} + e^{\theta_1}}, \quad p_1(\theta) = \frac{e^{\theta_1}}{e^{\theta_0} + e^{\theta_1}}$

Il parametro θ controlla l'intensità del rumore modulando la preservazione delle coerenze quantistiche.

Quantum Feature Embedding (Z_Q)

Al termine dei layer variazionali, si ottiene uno stato che codifica le feature del grafo.

Embedding Finale

Lo stato finale Z_Q dopo L layer di convoluzione quantistica è definito come:

$$Z_Q = \text{Tr}_{anc} \left(\prod_{l=1}^L \mathcal{N}_\theta^{(l)} (U_\theta^{(l)} \rho^{(l)} U_\theta^{(l)\dagger}) \right)$$

Entropia di Correlazione (C_Q)

Si calcola l'Entropia di Correlazione Quantistica per catturare le interazioni multi-partito.

Entropia di Correlazione

$$C_Q = \sum_{i \neq j} Tr \left(\rho_{ij}^{(L)} \log \rho_{ij}^{(L)} - \rho_i^{(L)} \log \rho_i^{(L)} - \rho_j^{(L)} \log \rho_j^{(L)} \right)$$

Valori elevati di C_Q indicano strutture di entanglement complesse, spesso correlate ad anomalie organizzate.

Analisi Topologica Persistente (TDA)

Sulla matrice densità finale $\rho^{(L)}$ viene costruita una metrica di distanza quantistica $d_\rho(i, j)$. Tramite filtrazione di Vietoris-Rips, si estraggono gli invarianti topologici:

- **Numeri di Betti** β_k : Conteggio di componenti connesse (β_0), cicli (β_1) e cavità (β_2).
- **Caratteristica di Eulero Persistente** χ^Q :

$$\chi^Q(\epsilon) = \sum_k (-1)^k \beta_k^Q(\epsilon)$$

Tali invarianti offrono una "firma digitale" della forma globale del grafo.

Classificatore Ibrido

Le feature quantistiche estratte vengono concatenate in un vettore:

$$\phi(G) = [Z_Q, C_Q, \{\beta_i^Q\}, \chi^Q]$$

Il modello viene addestrato minimizzando una funzione di costo ibrida:

$$\mathcal{L} = \mathcal{L}_{\text{sup}}(\hat{y}, y) + \lambda_1 \min_{m \in \mathcal{M}} \|\phi(G) - m\|^2 + \lambda_2 \|\Theta\|^2$$

Definizione della Loss supervisionata

Il vettore $\phi(G)$ è dato in input ad un classificatore classico che stima la probabilità di frode \hat{y} :

$$\hat{y} = \sigma(\mathbf{W}^\top \phi(G) + b)$$

La loss supervisionata è definita come la Binary Cross-Entropy tra la previsione e l'etichetta reale y :

$$\mathcal{L}_{\text{sup}}(\hat{y}, y) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

Classificazione Finale

Una volta allenato il modello la classificazione finale di un grafo G avviene calcolando un punteggio di anomalia:

$$s(G) = \min_{\phi(G^*) \in S_{normal}} \|\phi(G) - \phi(G^*)\|_2^2$$

Dove S_{normal} è l'insieme delle feature di grafi etichettati come normali presi da un validation set.

La decisione finale è basata su una soglia τ :

$$Fraud(G) = \begin{cases} 1(\text{Frode}) & \text{se } s(G) > \tau \\ 0(\text{Normale}) & \text{altrimenti} \end{cases}$$

Dettagli Implementativi e Training

Iperparametri

| Parametro | Valore |
|--|--------------------------|
| Nodi per Sottografo (N) | 16 |
| Qubit Totali ($2 \cdot \log_2 N$) | 8 |
| Dimensione Training Set | 700 |
| Dimensione Test Set | 100 |
| Layer VQGC (L) | 3 |
| Numeri di Betti Calcolati | Fino a β_1 (Cicli) |
| Epochs | 20 |
| Learning Rate | 0.005 |
| Lambda Loss (λ_1, λ_2) | 0.1, 0.01 |
| Dimensione Memory Bank (K) | 10 |
| Soglia Anomalia (τ) | 0.4 |
| Dimensione S_{normal} | 10 |

L'ambigua definizione di S_{normal}

Problema

S_{normal} va utilizzato sia durante il training (loss) che durante l'inferenza (classificazione). Nel paper originale S_{normal} è richiesto in input e definito come:

$(\phi(G_1), \phi(G_2), \dots, \phi(G_K))$, dove G_i sono grafi leciti

Tuttavia, questa scelta presenta un'enorme criticità:

Non è possibile conoscere $\phi(G)$ prima della fase di training.

Soluzione Proposta: Memory Bank Dinamica

In fase di training si utilizza una **Memory Bank** dinamica:

$$S_{normal} \equiv \mathcal{M}^{(t)} = \{m_1, m_2, \dots, m_K\}$$

- ① **Inizializzazione:** $\mathcal{M}^{(0)}$ è popolato con $\{\phi(G_i)\}_{i=1}^K$, t.c. G_i leciti.
- ② **Aggiornamento:** Utilizzando una politica FIFO ad ogni iterazione di Stochastic Gradient Descent si aggiorna una parte della Memory Bank.

Un primo tentativo basato su “*Deep One-Class Classification*” si è rilevato inadeguato poichè l’assunzione che i dati leciti fossero contenuti in un’ipersfera si è rivelata falsa.

Analisi Sperimentale e Conclusioni

Dataset PaySim

L'algoritmo è stato testato sul dataset sintetico **PaySim**. Un'analisi preliminare (script `calculate_density.py`) ha evidenziato gravi limitazioni strutturali:

- **Sparsità:** Il 94.83% dei nodi possiede grado 1. Solo il 5.17% ha grado ≥ 2 .
- **Assenza di Cicli:** Anche isolando le componenti debolmente connesse più grandi, i cicli e le strutture complesse sono rarissimi.

Impatto: Questa topologia “piatta” invalida parzialmente l'efficacia del modello, che si basa sull'identificazione di strutture topologiche complesse.

Risultati Sperimentali e Analisi di $\Phi(G)$

Metriche Finali: Accuracy: 70.0% (TP=3, FP=0, TN=84, FN=13)

1. Strutture Topologiche Simili (Falsi Negativi)

Graph 117 | NORMAL | Score: 0.000000 | Pred: 0

$\Phi(117) = [0.1628, 2.1829, 1.0, 0.0, 0.0, 1.0, 1.0, 0.0, 0.0, 1.0, 0.0625, 1.0625, 0.0, -1.0]$

Graph 002 | FRAUD | Score: 0.000009 | Pred: 0

$\Phi(002) = [0.1641, 2.1785, 1.0, 0.0, 0.0, 1.0, 1.0, 0.0, 0.0, 1.0, 0.0625, 1.0625, 0.0, -1.0]$

2 Variazioni Topologiche (Rilevamento Efficace)

Graph 068 | FRAUD | Score: 0.406291 | Pred: 1

$\Phi(068) = [0.1571, 2.1855, 1.0, 0.0, 0.0, 1.0, 1.0, 0.0, 0.0, 1.0, \mathbf{0.1875}, \mathbf{0.6875}, 0.0, -0.50]$

Graph 016 | FRAUD | Score: 2.115981 | Pred: 1

$\Phi(016) = [0.1239, 2.3273, 1.0, 1.0, 0.0, 1.0, 1.0, 0.0, 0.0, 1.0, \mathbf{0.3125}, \mathbf{0.1875}, 0.0, \mathbf{0.1250}]$

Considerazioni Finali

Conclusioni

Sebbene la natura sintetica e semplice di PaySim non abbia permesso di sfruttare appieno il potenziale del modello, l'esperimento dimostra che:

- ① L'architettura ibrida stima correttamente i Numeri di Betti e la Caratteristica di Eulero.
- ② La Memory Bank stabilizza l'apprendimento evitando il collasso su un centro inesatto.
- ③ L'algoritmo possiede un alto potenziale per scenari reali (non sintetici), dove le frodi si manifestano attraverso strutture topologiche complesse (es. anelli di riciclaggio).

Grazie per l'attenzione

Riferimenti Bibliografici I

- [1] S. Alarfaj F. K. Shahzadi. “Enhancing fraud detection in banking with deep learning: Graph neural networks and autoencoders for real-time credit card fraud prevention”. In: *Journal of Financial Data Science* (2024).
- [2] Mohammad Doost e Mohammad Manthouri. “Quantum topological graph neural networks for detecting complex fraud patterns”. In: *arXiv preprint arXiv:2512.03696* (2025). URL: <https://arxiv.org/abs/2512.03696v1>.
- [3] Edward Farhi, Jeffrey Goldstone e Sam Gutmann. “A Quantum Approximate Optimization Algorithm”. In: (2014). arXiv: 1411.4028 [quant-ph]. URL: <https://arxiv.org/abs/1411.4028>.

Riferimenti Bibliografici II

- [4] Hdaib M. e L. Rajasegarar S. Pan. “Quantum deep learning-based anomaly detection for enhanced network security”. In: *Quantum Machine Intelligence* 6.1 (2024).
- [5] M. J. Bastian N. D. Monkam G. F. De Lucia. “A topological data analysis approach for detecting data poisoning attacks against machine learning based network intrusion detection systems”. In: *Computers Security* 144 (2024).
- [6] B. Motie S. Raahemi. “Financial fraud detection using graph neural networks: A systematic review”. In: *Expert Systems with Applications* 240 (2024).
- [7] María Laura Olivera-Atencio, Lucas Lamata e Jesús Casado-Pascual. “Impact of Amplitude and Phase Damping Noise on Quantum Reinforcement Learning: Challenges and Opportunities”. In: (2025). arXiv: 2503.24069 [quant-ph]. URL: <https://arxiv.org/abs/2503.24069>.

Riferimenti Bibliografici III

- [8] T. Pourhabibi et al. “Fraud detection: A systematic literature review of graph-based anomaly detection approaches”. In: *Decision Support Systems* 133 (2020), p. 113303.
- [9] Lukas Ruff et al. “Deep One-Class Classification”. In: *Proceedings of the 35th International Conference on Machine Learning*. A cura di Jennifer Dy e Andreas Krause. Vol. 80. Proceedings of Machine Learning Research. PMLR, ott. 2018, pp. 4393–4402. URL:
<https://proceedings.mlr.press/v80/ruff18a.html>.
- [10] Y. Umeda, J. Kaneko e H. Kikuchi. “Topological data analysis and its application to time-series data analysis”. In: *Fujitsu Scientific and Technical Journal* 55 (2019), pp. 65–71.

Riferimenti Bibliografici IV

- [11] Xingbao Zhang, Wei Li e Yue Zhao. “One-class Anomaly Detection with Redundancy Reduction and Momentum Mechanism”. In: (2022), pp. 1–6.
DOI: [10.1109/DOCS55193.2022.9967719](https://doi.org/10.1109/DOCS55193.2022.9967719).